

Week3-5

1. 학습정리

1. GAN

1. 생성모델

1. 이미지를 샘플링 하는 모델
2. 어노탈리 디텍션
3. 입력이 주어졌을 때 확률 값을 얻어낼 수 있음 (explicit model)
4. 피쳐 러닝

2. 파라미터 수

1. 경우의 수 n
2. 파라미터 수 = $n-1$
3. 이미지에서 픽셀 하나당 RGB 각각 파라미터 255개 필요
4. 픽셀총 $255*255*255$ 개의 파라미터가 필요
5. 흑백 이미지는 픽셀 하나당 2개의 경우의 수
6. 이미지 크기가 m 이면 파라미터 수 = 2^m-1 개
7. 하지만 각 픽셀이 독립적이라고 가정하면
8. 파라미터 수는 $n-1$ 개로 줄어듦
9. 하지만 이렇게 하면 일반적인 이미지가 아님
10. 컨디셔널 인디펜던스 사용해서 파라미터 수도 줄이면서 위의 단점도 해결

3. 컨디셔널 인디펜던스

Conditional Independence

● Three important rules

● Chain rule:

$$p(x_1, \dots, x_n) = p(x_1)p(x_2 | x_1)p(x_3 | x_1, x_2) \cdots p(x_n | x_1, \dots, x_{n-1})$$

● Bayes' rule:

$$p(x | y) = \frac{p(x, y)}{p(y)} = \frac{p(y | x)p(x)}{p(y)}$$

● Conditional independence:

$$\text{If } x \perp y | z, \text{ then } p(x | y, z) = p(x | z)$$

..

Conditional Independence

- Using the chain rule,

$$p(x_1, \dots, x_n) = p(x_1)p(x_2|x_1)p(x_3|x_1, x_2)\cdots p(x_n|x_1, \dots, x_{n-1})$$

- How many parameters?

- $p(x_1)$: 1 parameter
- $p(x_2|x_1)$: 2 parameters (one per $p(x_2|x_1=0)$ and one per $p(x_2|x_1=1)$)
- $p(x_3|x_1, x_2)$: 4 parameters
- Hence, $1 + 2 + 2^2 + \dots + 2^{n-1} = 2^n - 1$, which is the same as before.

Conditional Independence

- Now, suppose $X_{i+1} \perp X_1, \dots, X_{i-1} | X_i$ (Markov assumption), then

$$p(x_1, \dots, x_n) = p(x_1)p(x_2|x_1)p(x_3|x_2)\cdots p(x_n|x_{n-1})$$

- How many parameters?

$$2n - 1$$

- Hence, by leveraging the Markov assumption, we get exponential reduction on the number of parameters.

1. z가 주어졌을때 x와 y가 독립적이면 y는 고려 안함
2. i+1 번째 픽셀은 i번째 픽셀과만 디펜던트 하다고 가정
3. 이렇게 하면 체인룰에 의해 파라미터 수가 2n-1개로 줄

2. 오토 리그레시브 모델

1. 이전 n개의 정보들에 대해서만 디펜던트 한 모델
2. 이미지에 순서를 매겨야 함

3. NADE

1. i번째 픽셀은 이전 i-1개의 입력에 디펜던트한 모델
2. explicit 모델
 1. 확률분포 계산가능
 2. implicit 모델은 생성만 가능

3. Variational Auto-encoder

Variational Auto-encoder

● But how?

$$\begin{aligned}\ln p_{\theta}(D) &= \mathbb{E}_{q_{\phi}(z|x)} [\ln p_{\theta}(x)] \\ &= \mathbb{E}_{q_{\phi}(z|x)} \left[\ln \frac{p_{\theta}(x, z)}{p_{\theta}(z|x)} \right] \\ &= \mathbb{E}_{q_{\phi}(z|x)} \left[\ln \frac{p_{\theta}(x, z) q_{\phi}(z|x)}{q_{\phi}(z|x) p_{\theta}(z|x)} \right] \\ &= \mathbb{E}_{q_{\phi}(z|x)} \left[\ln \frac{p_{\theta}(x, z)}{q_{\phi}(z|x)} \right] + \mathbb{E}_{q_{\phi}(z|x)} \left[\ln \frac{q_{\phi}(z|x)}{p_{\theta}(z|x)} \right] \\ &= \underbrace{\mathbb{E}_{q_{\phi}(z|x)} \left[\ln \frac{p_{\theta}(x, z)}{q_{\phi}(z|x)} \right]}_{\text{ELBO } \uparrow} + \underbrace{D_{KL}(q_{\phi}(z|x) || p_{\theta}(z|x))}_{\text{Objective } \downarrow}\end{aligned}$$

Importantly, **ELBO** is a tractable quantity.

VI minimizes the (intractable) **objective** via maximizing **ELBO**.

1. Variational inference

1. Posterior distribution 을 찾는 것
2. 내가 관심있어 하는 랜덤 변수에 대한 확률 분포
3. Variational distribution 으로 posterior 을 근사해서 실제론 이걸 찾음
4. 이 목적은 ELBO 를 최대화 해서 달성가능

4. GAN

1. 구조
 1. 제네레이터가 만든 것과 진짜를 비교
 2. 판별자는 더 잘 구분하게 학습
 3. 생성자는 더 잘 속이는 것을 생성하도록 학습
2. 장점
 1. 생성자와 판별자가 서로 좋아짐

2. 피어세션

1. 강의리뷰
 1. 어려웠음
 2. 레퍼런스로 소개된 영상 찾아볼 것
 3. GAN 에서 각각의 역할
2. 깃 리베이스
 1. 리베이스 실습